Praktikum Pembelajaran Mesin

Laporan Tugas Clustering K-Means dan K-Prototype



Disusun Oleh :

Kelompok : 4

Kelas : TI C7

Anggota :

1. **Okta Roman Sanjaya (434241108)**
2. **Rafi Fernandito Setiawan (434241117)**
3. **Rafi Hariman Priambodo (434241115)**

Link Dataset :

https://www.kaggle.com/competitions/computer-prices-2025/data

FAKULTAS VOKASI

UNIVERSITAS

AIRLANGGA 2026

BAB I. PENDAHULUAN....3
1.1 Latar Belakang....3
1.2 Rumusan Masalah....4
1.3 Tujuan....4
BAB II. DESKRIPSI DATASET....4
2.1 Sumber Dataset....4
2.2 Deskripsi Dataset....5
2.3 Variabel Target....5
2.4 Pembagian Data Eksperimen....6
BAB III. METODOLOGI DAN IMPLEMENTASI....6
3.1 Tahapan Penelitian....6
3.2 Preprocessing Data....7
A. Pemisahan Fitur dan Target....7
B. Penanganan Missing Value....7
C. Encoding Data Kategorikal....7
D. Pembagian Data....7
3.3 Implementasi Algoritma AdaBoost....8
3.4 Implementasi Algoritma Gradient Boosting....8
3.5 Proses Training dan Testing....9
BAB IV. HASIL DAN PEMBAHASAN....9
4.1 Hasil Training Model....9
4.2 Evaluasi Model....10
4.3 Hasil Perbandingan Model....10
4.5 Penentuan Model Terbaik....11
BAB V. IMPLEMENTASI UI/UX APLIKASI....12
5.1 Gambaran Umum Aplikasi....12
5.2 Halaman Dashboard....12
5.3 Halaman Prediksi Harga....13
5.4 Halaman Evaluasi Model....14
5.5 Halaman Tentang Aplikasi....15
5.6 Teknologi yang Digunakan....16
BAB VI. KESIMPULAN DAN SARAN....17
6.1 Kesimpulan....17
6.2 Saran....17
DAFTAR PUSTAKA....18

BAB I. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi komputer menyebabkan semakin beragamnya jenis dan spesifikasi perangkat komputer yang tersedia di pasaran. Setiap komputer memiliki karakteristik yang berbeda, seperti merek, jenis perangkat, prosesor, kapasitas RAM, penyimpanan, kartu grafis, dan spesifikasi lainnya. Perbedaan karakteristik tersebut dapat memengaruhi harga jual suatu komputer.

Machine Learning merupakan salah satu teknologi yang dapat digunakan untuk mempelajari pola dari data dan menghasilkan prediksi berdasarkan informasi yang tersedia. Dalam tugas ini, Machine Learning diterapkan untuk memperkirakan harga komputer berdasarkan spesifikasi perangkat keras yang dimiliki.

Algoritma yang digunakan adalah AdaBoost (Adaptive Boosting) dan Gradient Boosting. Kedua algoritma tersebut merupakan metode ensemble learning yang menggabungkan beberapa model pembelajaran untuk menghasilkan prediksi yang lebih baik.

Melalui penelitian ini, dilakukan pelatihan, pengujian, serta perbandingan performa kedua algoritma untuk mengetahui model yang memberikan hasil prediksi harga komputer paling baik. Model terbaik kemudian diimplementasikan ke dalam aplikasi berbasis web **menggunakan Streamlit.**

1.2 Rumusan Masalah

1. Bagaimana menerapkan algoritma AdaBoost dan Gradient Boosting untuk memprediksi harga komputer?
2. Bagaimana membandingkan performa kedua algoritma berdasarkan MAE, MAPE, MSE, RMSE, dan R^2?
3. Algoritma manakah yang menghasilkan performa prediksi terbaik?
4. Bagaimana mengimplementasikan model terbaik ke dalam aplikasi prediksi harga komputer?

1.3 Tujuan

1. Menerapkan algoritma AdaBoost dan Gradient Boosting pada dataset harga komputer.
2. Melakukan proses training dan testing menggunakan data yang telah dipersiapkan.
3. Mengevaluasi dan membandingkan hasil prediksi dari kedua algoritma.
4. Menentukan model terbaik berdasarkan hasil evaluasi.
5. Membuat aplikasi berbasis web untuk melakukan prediksi harga komputer berdasarkan spesifikasi perangkat.

BAB II. DESKRIPSI DATASET

2.1 Sumber Dataset

Dataset yang digunakan dalam penelitian ini adalah Computer Prices 2025 yang diperoleh dari Kaggle.

Dataset tersebut berisi informasi mengenai berbagai jenis komputer beserta spesifikasi perangkat keras dan harga masing-masing perangkat.

Sumber dataset:
[Masukkan tautan Kaggle dataset Computer Prices 2025]

2.2 Deskripsi Dataset

Dataset Computer Prices 2025 memiliki jumlah data asli sebanyak 100.000 baris dengan 34 kolom. Kolom-kolom tersebut terdiri dari identitas perangkat, karakteristik komputer, dan harga.

Target prediksi yang digunakan adalah kolom price, yaitu nilai harga komputer. Sementara itu, kolom ID tidak digunakan sebagai fitur karena hanya berfungsi sebagai identitas data.

Dengan demikian, terdapat 32 fitur prediktor yang digunakan untuk memperkirakan harga komputer.

Beberapa fitur yang digunakan antara lain:

1. device_type: jenis perangkat komputer.
2. brand: merek komputer.
3. model: model komputer.
4. release_year: tahun peluncuran perangkat.
5. os: sistem operasi.
6. cpu_brand: merek prosesor.
7. cpu_model: model prosesor.
8. cpu_cores: jumlah inti prosesor.
9. ram_gb: kapasitas RAM.
10. storage_type: jenis penyimpanan.
11. storage_gb: kapasitas penyimpanan.
12. gpu_brand: merek kartu grafis.
13. vram_gb: kapasitas memori kartu grafis.
14. display_size_in: ukuran layar.
15. refresh_hz: tingkat refresh rate layar.
16. weight_kg: berat perangkat.
17. warranty_months: masa garansi.

Selain fitur tersebut, dataset juga memiliki informasi lain seperti jenis casing, kecepatan prosesor, resolusi layar, konektivitas, baterai, dan spesifikasi pendukung lainnya.

2.3 Variabel Target

Variabel target dalam penelitian ini adalah:

price

Kolom tersebut merupakan nilai harga komputer yang akan diprediksi oleh model berdasarkan 32 fitur spesifikasi perangkat.

2.4 Pembagian Data Eksperimen

Dataset asli memiliki 100.000 baris. Untuk mempercepat proses eksperimen, penelitian ini menggunakan sampel sebanyak 25.000 baris dengan pengambilan sampel secara acak menggunakan random_state=42.

Pembagian data dilakukan dengan rasio 80:20, yaitu:

Jenis Data	Jumlah
Dataset asli	100.000
Data eksperimen	25.000
Data training (80%)	20.000
Data testing (20%)	5.000

Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk mengukur kemampuan model dalam memprediksi data yang tidak digunakan selama proses pelatihan.

Gambar 2.1. Dataset Computer Prices 2025
[Masukkan screenshot dataset yang dibuka dalam bentuk tabel.]

BAB III. METODOLOGI DAN IMPLEMENTASI

3.1 Tahapan Penelitian

Penelitian ini dilakukan melalui beberapa tahapan, yaitu:

1. Pengumpulan dataset Computer Prices 2025.
2. Pemeriksaan dan pemilihan fitur dataset.
3. Preprocessing data.
4. Pembagian data training dan testing.
5. Pembuatan model AdaBoost.
6. Pembuatan model Gradient Boosting.
7. Evaluasi dan perbandingan hasil model.
8. Pemilihan model terbaik.
9. Implementasi model ke dalam aplikasi berbasis web.

3.2 Preprocessing Data

Preprocessing merupakan tahapan persiapan data sebelum digunakan dalam proses pelatihan Machine Learning. Tahapan ini dilakukan agar data dapat diproses oleh algoritma secara lebih terstruktur.

Pada penelitian ini, preprocessing dilakukan menggunakan beberapa teknik berikut.

A. Pemisahan Fitur dan Target

Kolom price ditentukan sebagai variabel target yang akan diprediksi. Kolom ID dihapus karena tidak memberikan informasi spesifikasi yang diperlukan dalam proses prediksi.

Seluruh kolom spesifikasi lainnya digunakan sebagai fitur prediktor.

B. Penanganan Missing Value

Penanganan missing value dilakukan menggunakan metode imputasi.

- Pada fitur numerik digunakan SimpleImputer dengan strategi median.
- Pada fitur kategorikal digunakan SimpleImputer dengan strategi nilai yang paling sering muncul atau modus.

Teknik ini digunakan agar data yang memiliki nilai kosong tetap dapat diproses oleh model.

C. Encoding Data Kategorikal

Data kategorikal seperti merek, jenis perangkat, sistem operasi, dan jenis penyimpanan perlu diubah menjadi bentuk numerik.

Pada penelitian ini digunakan OrdinalEncoder dengan pengaturan handle_unknown='use_encoded_value' dan unknown_value=-1.

Dengan demikian, kategori yang belum pernah ditemukan pada data training tetap dapat ditangani ketika model menerima data baru.

D. Pembagian Data

Setelah preprocessing disiapkan, data dibagi menjadi data training dan testing dengan rasio 80:20.

Sebanyak 20.000 baris digunakan untuk training dan 5.000 baris digunakan untuk testing.

Preprocessing diterapkan menggunakan ColumnTransformer dan Pipeline agar proses penanganan fitur numerik serta kategorikal dilakukan secara konsisten.

3.3 Implementasi Algoritma AdaBoost

AdaBoost merupakan singkatan dari Adaptive Boosting, yaitu algoritma ensemble learning yang menggabungkan beberapa weak learner menjadi model yang lebih kuat.

Cara kerja AdaBoost adalah membangun model secara bertahap. Model berikutnya memberikan perhatian lebih terhadap data yang sebelumnya sulit diprediksi sehingga kesalahan prediksi dapat diperbaiki secara bertahap.

Pada penelitian ini, AdaBoost diimplementasikan menggunakan AdaBoostRegressor dengan konfigurasi:

- Estimator dasar: DecisionTreeRegressor.
- Kedalaman maksimum pohon: 2.
- Jumlah estimator: 30.
- Learning rate: 0,05.
- Random state: 42.

Model dilatih menggunakan data training, kemudian digunakan untuk memprediksi harga pada data testing.

3.4 Implementasi Algoritma Gradient Boosting

Gradient Boosting merupakan algoritma ensemble learning yang membangun model secara bertahap dengan memperbaiki kesalahan prediksi dari model sebelumnya.

Setiap model baru berusaha mempelajari residual atau selisih antara nilai aktual dan hasil prediksi sebelumnya. Proses tersebut dilakukan secara berulang hingga menghasilkan model dengan kesalahan prediksi yang lebih kecil.

Pada penelitian ini, Gradient Boosting diimplementasikan menggunakan GradientBoostingRegressor dengan konfigurasi:

- Jumlah estimator: 50.
- Learning rate: 0,05.
- Kedalaman maksimum pohon: 2.
- Subsample: 0,8.
- Random state: 42.

Model kemudian dilatih menggunakan data training dan diuji menggunakan data testing.

3.5 Proses Training dan Testing

Proses training dilakukan dengan memberikan data training kepada masing-masing algoritma agar model dapat mempelajari hubungan antara spesifikasi komputer dan harga.

Setelah proses training selesai, kedua model digunakan untuk menghasilkan prediksi terhadap data testing.

Nilai prediksi tersebut kemudian dibandingkan dengan nilai harga sebenarnya untuk memperoleh hasil evaluasi.

Proses ini bertujuan mengetahui kemampuan masing-masing algoritma dalam memprediksi harga komputer pada data yang belum digunakan selama pelatihan.

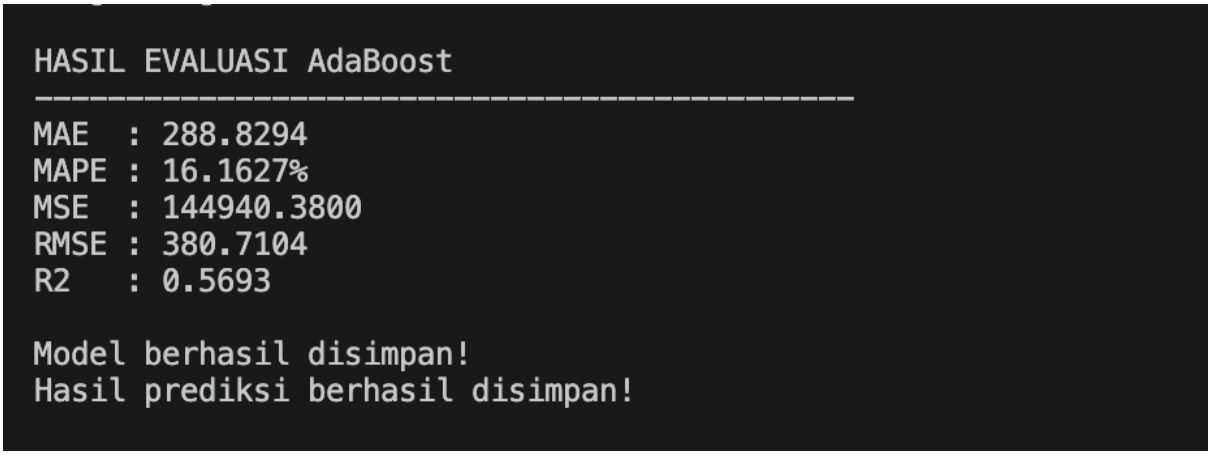
BAB IV. HASIL DAN PEMBAHASAN

4.1 Hasil Training Model

Berdasarkan proses pelatihan yang telah dilakukan, diperoleh waktu training sebagai berikut:

Algoritma	Waktu Training
AdaBoost	1,2581 detik
Gradient Boosting	1,5850 detik

Hasil tersebut menunjukkan bahwa AdaBoost memiliki waktu pelatihan yang sedikit lebih cepat dibandingkan Gradient Boosting. Namun, kecepatan training bukan satu-satunya faktor dalam menentukan model terbaik. Performa prediksi juga perlu diperhatikan melalui hasil evaluasi.



4.2 Evaluasi Model

Evaluasi dilakukan menggunakan lima metrik, yaitu MAE, MAPE, MSE, RMSE, dan R^2.

Berikut merupakan penjelasan masing-masing metrik:

1. MAE (Mean Absolute Error) mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. Semakin kecil nilainya, semakin baik hasil prediksi.
2. MAPE (Mean Absolute Percentage Error) mengukur rata-rata persentase kesalahan prediksi. Semakin kecil nilainya, semakin baik.
3. MSE (Mean Squared Error) menghitung rata-rata kuadrat kesalahan prediksi. Nilai yang lebih kecil menunjukkan kesalahan yang lebih rendah.
4. RMSE (Root Mean Squared Error) merupakan akar dari MSE dan menunjukkan besarnya kesalahan prediksi dalam satuan target.

5. R^2 (Coefficient of Determination) menunjukkan seberapa besar variasi nilai target dapat dijelaskan oleh model. Semakin mendekati 1, semakin baik kemampuan model dalam menjelaskan variasi data.

4.3 Hasil Perbandingan Model

Berdasarkan pengujian terhadap 5.000 data testing, diperoleh hasil sebagai berikut:

Metrik	AdaBoost	Gradient Boosting
MAE	288,8294	237,5351
MAPE	16,1627%	13,2656%
MSE	144.940,3800	105.827,4156
RMSE	380,7104	325,3113
R^2	0,5693	0,6856

```
============================================================
       PERBANDINGAN HASIL EVALUASI MODEL
============================================================
            Model      MAE    MAPE         MSE     RMSE     R2  Waktu_Training
         AdaBoost 288.8294 16.1627 144940.3800 380.7104 0.5693          1.2581
Gradient Boosting 237.5351 13.2656 105827.4156 325.3113 0.6856          1.5850
```

4.4 Analisis Hasil Evaluasi

Berdasarkan hasil evaluasi, Gradient Boosting memperoleh hasil yang lebih baik dibandingkan AdaBoost pada seluruh metrik yang digunakan.

Pada metrik MAE, Gradient Boosting menghasilkan nilai 237,5351, lebih rendah dibandingkan AdaBoost yang memperoleh nilai 288,8294. Hal ini menunjukkan bahwa rata-rata kesalahan absolut prediksi Gradient Boosting lebih kecil.

Pada metrik MAPE, Gradient Boosting memperoleh nilai 13,2656%, sedangkan AdaBoost memperoleh 16,1627%. Hasil ini menunjukkan bahwa persentase kesalahan prediksi Gradient Boosting lebih rendah.

Pada metrik MSE dan RMSE, Gradient Boosting juga menghasilkan nilai yang lebih kecil. Hal ini menunjukkan bahwa kesalahan prediksinya secara keseluruhan lebih rendah dibandingkan AdaBoost.

Sementara itu, nilai R^2 Gradient Boosting sebesar 0,6856 lebih tinggi dibandingkan AdaBoost sebesar 0,5693. Artinya, Gradient Boosting mampu menjelaskan sekitar 68,56% variasi harga pada data pengujian.

Dari hasil tersebut dapat disimpulkan bahwa Gradient Boosting memberikan performa prediksi yang lebih baik pada eksperimen ini.

4.5 Penentuan Model Terbaik

Berdasarkan hasil perbandingan lima metrik evaluasi, Gradient Boosting dipilih sebagai model terbaik.

Alasan pemilihan tersebut adalah:

1. Memiliki nilai MAE lebih rendah.
2. Memiliki nilai MAPE lebih rendah.
3. Memiliki nilai MSE lebih rendah.
4. Memiliki nilai RMSE lebih rendah.
5. Memiliki nilai R^2 lebih tinggi.

Walaupun waktu training Gradient Boosting sedikit lebih lama dibandingkan AdaBoost, hasil prediksinya menunjukkan tingkat kesalahan yang lebih rendah.

Oleh karena itu, model Gradient Boosting disimpan sebagai model terbaik dan digunakan pada aplikasi Computer Price Predictor.

BAB V. IMPLEMENTASI UI/UX APLIKASI

5.1 Gambaran Umum Aplikasi

Setelah proses training dan evaluasi selesai, model terbaik diimplementasikan ke dalam aplikasi berbasis web menggunakan Streamlit.

Aplikasi ini diberi nama Computer Price Predictor dan digunakan untuk memperkirakan harga komputer berdasarkan spesifikasi perangkat yang dimasukkan oleh pengguna.

Aplikasi memiliki empat menu utama, yaitu Dashboard, Prediksi Harga, Evaluasi Model, dan Tentang Aplikasi.

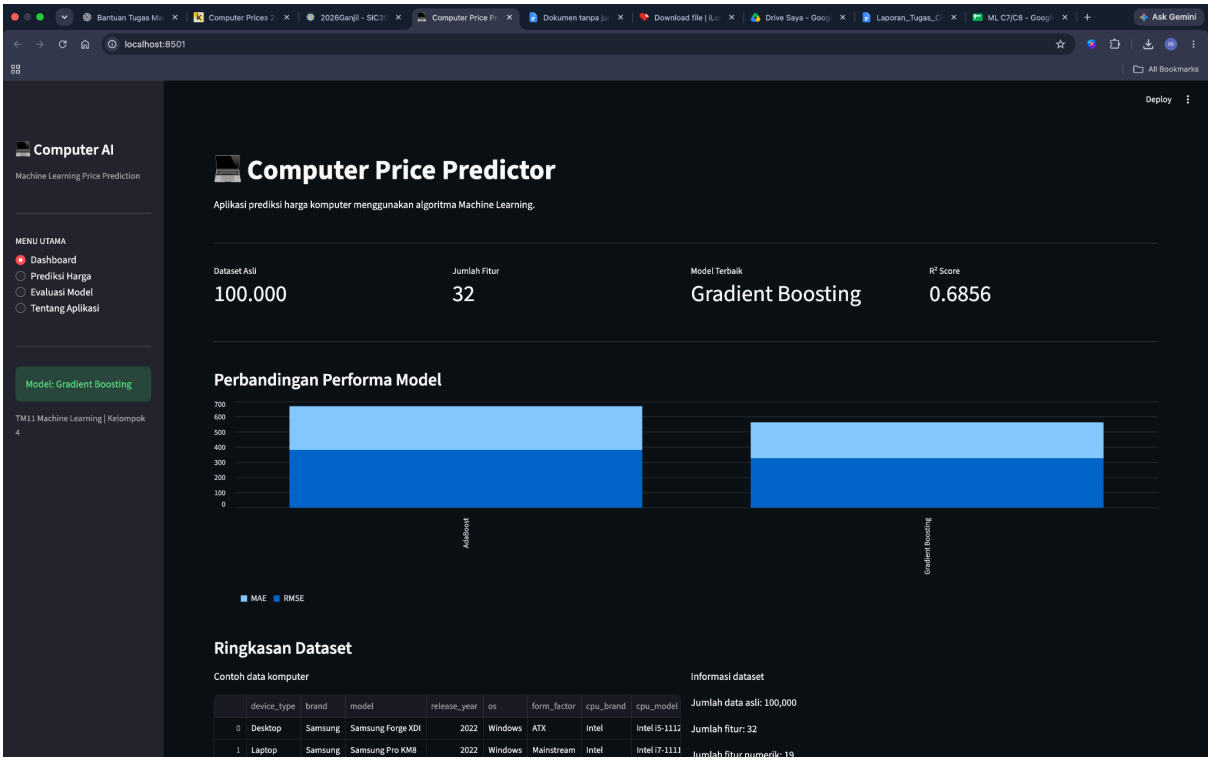
5.2 Halaman Dashboard

Halaman Dashboard merupakan halaman utama yang menampilkan ringkasan informasi mengenai dataset dan hasil eksperimen.

Informasi yang ditampilkan meliputi:

1. Jumlah dataset asli sebanyak 100.000 data.
2. Jumlah fitur sebanyak 32 fitur.
3. Model terbaik yaitu Gradient Boosting.
4. Nilai R^2 sebesar 0,6856.
5. Grafik perbandingan performa AdaBoost dan Gradient Boosting.
6. Contoh data komputer dari dataset.

Halaman ini membantu pengguna memahami gambaran umum sistem dan hasil pemodelan yang telah dilakukan.



5.3 Halaman Prediksi Harga

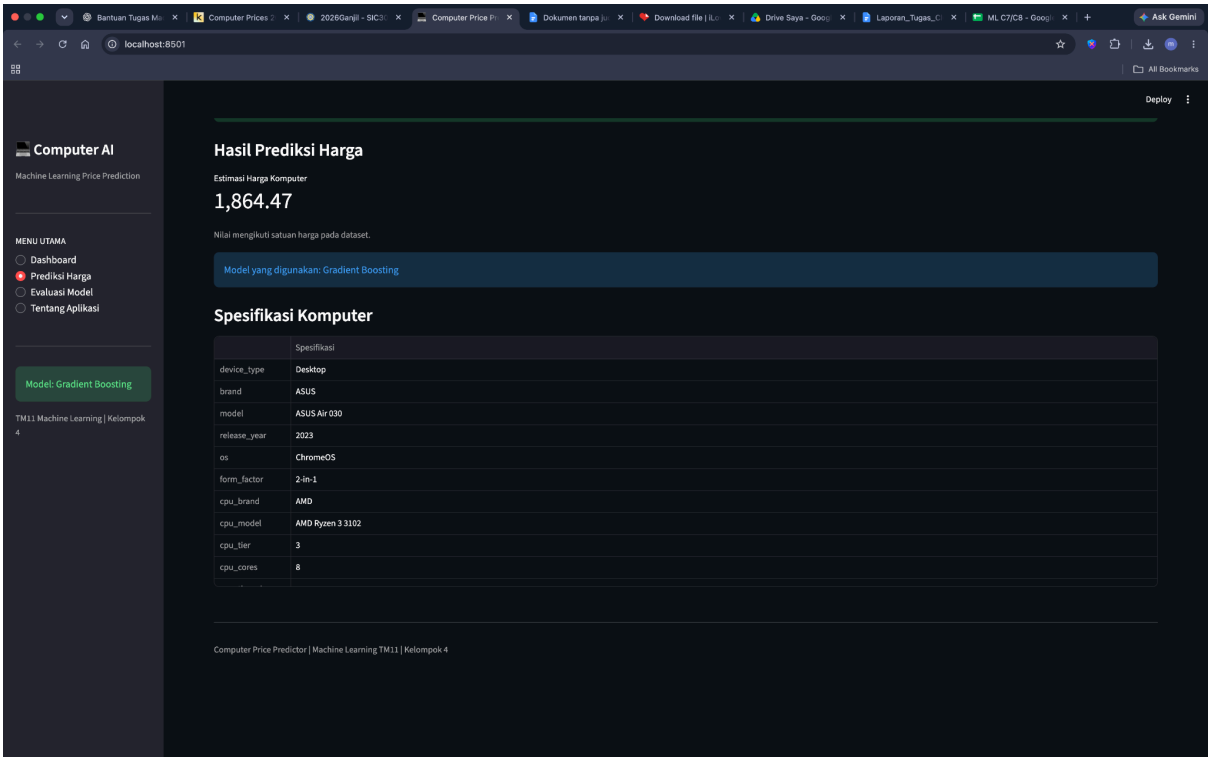
Halaman Prediksi Harga digunakan untuk melakukan estimasi harga komputer berdasarkan spesifikasi yang dimasukkan oleh pengguna.

Pengguna dapat memasukkan informasi seperti jenis perangkat, merek, model, tahun rilis, sistem operasi, prosesor, RAM, penyimpanan, kartu grafis, dan spesifikasi lainnya.

Setelah seluruh spesifikasi dimasukkan, pengguna dapat menekan tombol prediksi. Sistem kemudian memproses input menggunakan model Gradient Boosting yang telah dilatih sebelumnya.

Pada pengujian aplikasi, diperoleh salah satu hasil prediksi sebesar 1.864,47, sesuai satuan harga yang digunakan dalam dataset.

Hasil tersebut menunjukkan bahwa aplikasi berhasil menerima input pengguna dan menghasilkan estimasi harga menggunakan model Machine Learning.

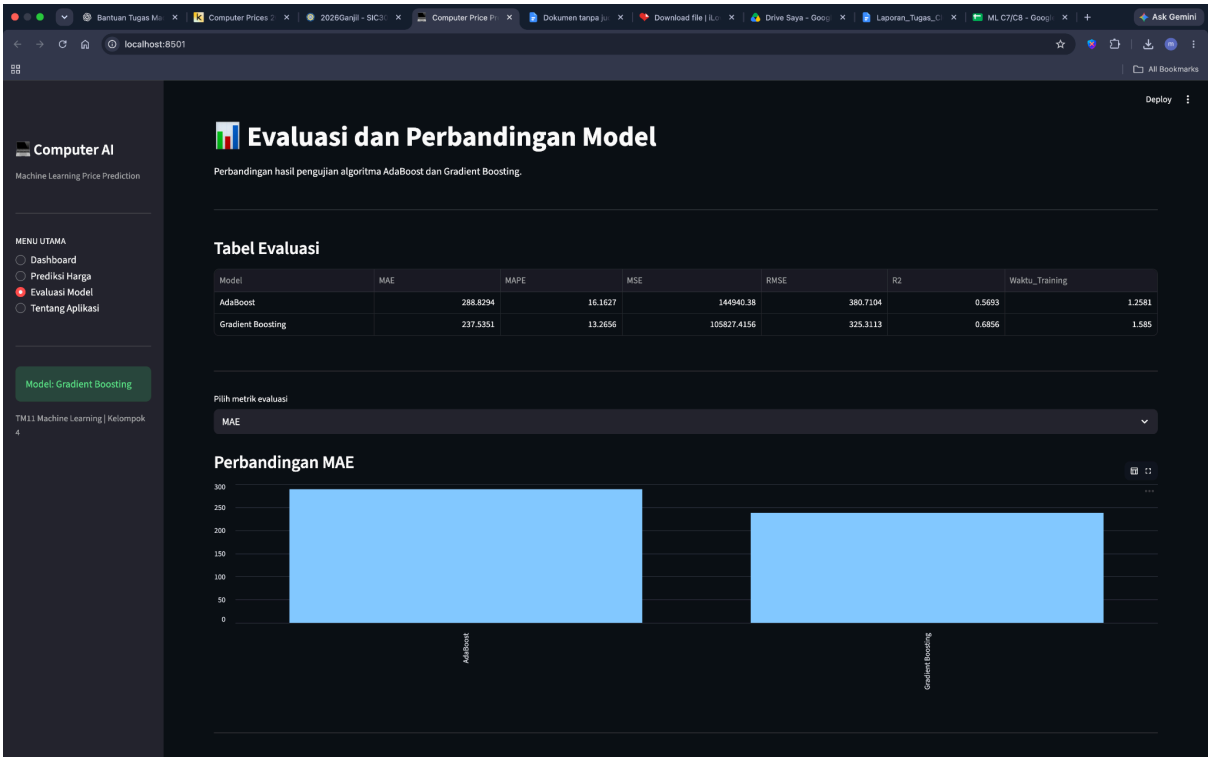


5.4 Halaman Evaluasi Model

Halaman Evaluasi Model menampilkan hasil perbandingan performa algoritma AdaBoost dan Gradient Boosting.

Informasi yang ditampilkan berupa tabel nilai MAE, MAPE, MSE, RMSE, R^2, dan waktu training. Selain tabel, tersedia grafik yang digunakan untuk membandingkan hasil evaluasi kedua algoritma.

Melalui halaman ini, pengguna dapat melihat alasan pemilihan Gradient Boosting sebagai model terbaik berdasarkan hasil pengujian.



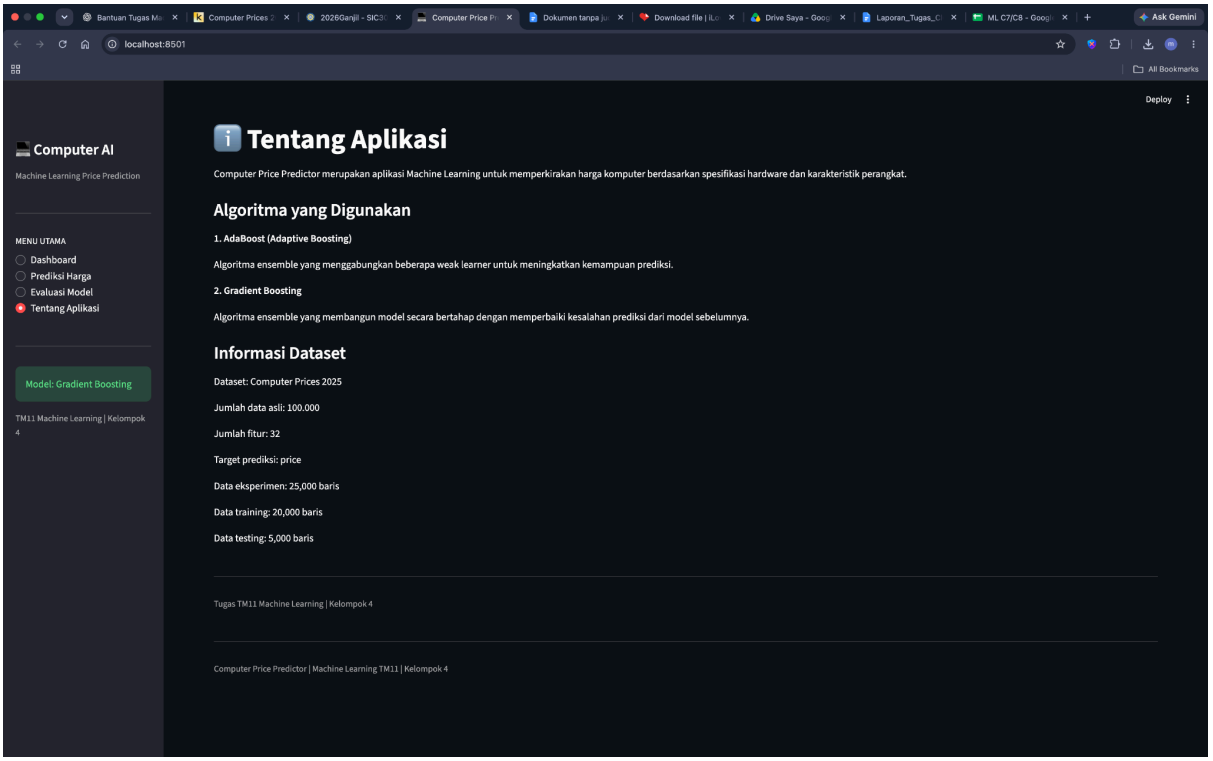
5.5 Halaman Tentang Aplikasi

Halaman Tentang Aplikasi memberikan informasi mengenai tujuan aplikasi, algoritma yang digunakan, serta dataset yang menjadi dasar proses prediksi.

Informasi yang ditampilkan meliputi:

- Nama dataset: Computer Prices 2025.
- Jumlah data asli: 100.000 baris.
- Jumlah fitur prediktor: 32 fitur.
- Target prediksi: price.
- Jumlah data eksperimen: 25.000 baris.
- Data training: 20.000 baris.
- Data testing: 5.000 baris.
- Algoritma: AdaBoost dan Gradient Boosting.

Halaman ini membantu pengguna memahami teknologi dan data yang digunakan dalam pengembangan aplikasi.



5.6 Teknologi yang Digunakan

Beberapa teknologi dan library yang digunakan dalam pengembangan sistem ini adalah:

1. Python: bahasa pemrograman utama untuk pengolahan data dan pengembangan model Machine Learning.
2. Pandas: digunakan untuk membaca dan mengolah dataset.
3. NumPy: digunakan untuk operasi numerik.
4. Scikit-learn: digunakan untuk preprocessing, training, testing, dan evaluasi model.
5. Joblib: digunakan untuk menyimpan dan memuat model Machine Learning.
6. Streamlit: digunakan untuk membangun antarmuka aplikasi berbasis web.

BAB VI. KESIMPULAN DAN SARAN

6.1 Kesimpulan

Berdasarkan penelitian dan implementasi yang telah dilakukan, dapat disimpulkan bahwa algoritma AdaBoost dan Gradient Boosting berhasil diterapkan untuk memprediksi harga komputer menggunakan dataset Computer Prices 2025.

Eksperimen dilakukan menggunakan 25.000 sampel data dari total 100.000 data asli. Data tersebut dibagi menjadi 20.000 data training dan 5.000 data testing dengan rasio 80:20.

Hasil evaluasi menunjukkan bahwa Gradient Boosting memberikan performa lebih baik dibandingkan AdaBoost. Gradient Boosting memperoleh MAE sebesar 237,5351, MAPE sebesar 13,2656%, MSE sebesar 105.827,4156, RMSE sebesar 325,3113, dan R^2 sebesar 0,6856.

Berdasarkan hasil tersebut, Gradient Boosting dipilih sebagai model terbaik karena memiliki kesalahan prediksi lebih rendah dan nilai R^2 lebih tinggi dibandingkan AdaBoost.

Model terbaik kemudian berhasil diimplementasikan ke dalam aplikasi berbasis web menggunakan Streamlit. Aplikasi memiliki empat menu utama, yaitu Dashboard, Prediksi Harga, Evaluasi Model, dan Tentang Aplikasi. Pengujian menunjukkan bahwa fitur prediksi dapat berjalan dan menghasilkan estimasi harga berdasarkan spesifikasi komputer yang dimasukkan.

Dengan demikian, penerapan Machine Learning pada penelitian ini berhasil menghasilkan sistem yang dapat digunakan untuk memperkirakan harga komputer berdasarkan karakteristik perangkat.

6.2 Saran

Untuk pengembangan selanjutnya, terdapat beberapa hal yang dapat dilakukan, yaitu:

1. Menggunakan seluruh data asli sebanyak 100.000 baris agar model dapat mempelajari lebih banyak variasi data.
2. Melakukan tuning hyperparameter untuk memperoleh konfigurasi model yang lebih optimal.
3. Membandingkan algoritma dengan metode Machine Learning lainnya.
4. Menambahkan fitur visualisasi yang lebih lengkap pada aplikasi.
5. Melakukan pengujian menggunakan data komputer terbaru agar hasil prediksi tetap relevan.

DAFTAR PUSTAKA

1. Dataset Computer Prices 2025. Kaggle. [Masukkan tautan dataset yang digunakan].
2. Scikit-learn Documentation. Ensemble Methods. https://scikit-learn.org/stable/modules/ensemble.html
3. Scikit-learn Documentation. Model Evaluation. https://scikit-learn.org/stable/modules/model_evaluation.html
4. Streamlit Documentation. https://docs.streamlit.io/